

8주차 보고서 (교정본)

Multi-Head Attention은 어떻게 다양한 관계를 학습하는가 — 실해석적 관점

Attention is All You Need 스터디 8주차 보고서의 교정본. 원본의 야심(측도·적분 연산자로 어텐션을 재해석하려는 시도)은 살리되, **차원·선형성·노름**에 관한 부정확한 주장을 엄밀하게 고쳤다. 각 섹션 끝의 핵심은 "직관이 가리키는 방향"이 아니라 "그게 왜 성립하는가"를 한 줄로 적는 것.

1. 정의와 차원

입력을 $X \in \mathbb{R}^{n \times d_{\text{model}}}$ 라 하자 (n = 토큰 수). Self-attention에서는 Q, K, V 의 원천이 모두 X 로 동일하고, head마다 다른 **projection**을 거친다.

head별 사상 행렬

$$W_i^Q, W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}, \quad W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$$

각 head의 입력 (사상 후)

$$Q_i = XW_i^Q, \quad K_i = XW_i^K \in \mathbb{R}^{n \times d_k}, \quad V_i = XW_i^V \in \mathbb{R}^{n \times d_v}$$

각 head의 출력

$$\text{head}_i = \text{softmax}\left(\frac{Q_i K_i^\top}{\sqrt{d_k}}\right) V_i \in \mathbb{R}^{n \times d_v}$$

결합과 최종 투영

$$\text{MultiHead}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_h), W^O$$

concat은 feature 축으로 붙으므로

$$\text{Concat}(\dots) \in \mathbb{R}^{n \times (h \cdot d_v)}, \quad W^O \in \mathbb{R}^{(h \cdot d_v) \times d_{\text{model}}}$$

표준 설정 $d_k = d_v = d_{\text{model}}/h$ 에서는 $h \cdot d_v = d_{\text{model}}$ 이므로

$$W^O \in \mathbb{R}^{d_{\text{model}} \times d_{\text{model}}}, \quad \text{MultiHead}(X) \in \mathbb{R}^{n \times d_{\text{model}}}$$

차원 불변식 (꼭 외울 것)

d_k 는 **shape에 안 보이는** 차원이다 — $Q_i K_i^\top$ 에서 contract되어 $n \times n$ 이 되고, 오직 스케일링 $\sqrt{d_k}$ 와 rank에만 영향을 준다. d_v 는 **shape를 타고 흐르는** 차원이다 — head → concat

→ W^O 입력까지 전파되지만, W^O 가 마지막에 흡수해 출력은 항상 d_{model} 로 고정된다. (출력이 d_{model} 로 보존되어야 residual로 X 에 더할 수 있다.)

2. 왜 여러 head인가 — "low-rank"는 맞고 "projection"은 틀리다

원본은 각 head가 Q, K, V 를 "low-rank subspace로 projection한다"고 썼다. 두 단어를 분리해 검증한다.

"projection"은 부정확하다. 선형대수에서 projection은 idempotent($P^2 = P$)이며 공간을 자기 자신의 부분공간으로 보낸다. 그러나 $W_i^Q \in \mathbb{R}^{d_{model} \times d_k}$ 는 $\mathbb{R}^{d_{model}} \rightarrow \mathbb{R}^{d_k}$ 로 다른 (더 작은) 공간에 보내며, P^2 자체가 차원이 맞지 않아 정의되지 않는다. 이것은 projection이 아니라 차원축소 선형사상이다. (그리고 W_i^Q 자체는 보통 rank d_k 인 full-rank 행렬이다.)

"low-rank"는 맞다 — 단, 이유가 다르다. 정확한 근거는 각 head의 query-key 상호작용 행렬을 d_{model} 공간으로 되돌려 보면 나온다:

$$Q_i K_i^\top = X, (W_i^Q (W_i^K)^\top), X^\top, \quad W_i^Q (W_i^K)^\top \in \mathbb{R}^{d_{model} \times d_{model}}$$

이때

$$\text{rank}(W_i^Q (W_i^K)^\top) \leq d_k \ll d_{model}.$$

증명 (한 줄). $W_i^Q (W_i^K)^\top$ 의 모든 열은 W_i^Q 열들의 선형결합이므로 그 열공간은 $\text{Col}(W_i^Q)$ 에 포함된다. W_i^Q 는 열이 d_k 개뿐이라 $\dim \text{Col}(W_i^Q) \leq d_k$. 따라서 $\text{rank} \leq d_k$. (동치로, 사상이 $\mathbb{R}^{d_{model}} \rightarrow \mathbb{R}^{d_k} \rightarrow \mathbb{R}^{d_{model}}$ 처럼 d_k 차원 공간을 통과(factor through)하므로 상이 최대 d_k 차원이다. 일반 부등식 $\text{rank}(AB) \leq \min(\text{rank } A, \text{rank } B)$ 도 같은 열/행공간 포함에서 나온다.)

의미. 각 head는 full d_{model} 상호작용 중 rank- d_k 짜리 한 조각만 본다. h 개 head로 쪼개면 h 개의 독립적인 rank- d_k 부분공간을 병렬로 보게 되어, 서로 다른 관계 패턴을 동시에 포착한다. 대가는 head 하나하나가 rank로 제한된다는 것 — 이것이 low-rank bottleneck으로 알려진 이슈다.

3. 어텐션의 연산자 해석 — value엔 선형, query엔 비선형

어텐션을 연속(적분) 형태로 이상화하면:

$$\text{head}_i(x) = \frac{\int_{\Omega} \Omega \alpha_i(x, y), V(y), d\mu(y)}{\int_{\Omega} \exp! \left(\frac{Q(x)K(y)^{\top}}{\sqrt{d_k}} \right), d\mu(y)}.$$

선형성은 V 에 대해서만, 그것도 가중치를 고정했을 때만 성립한다. 커널 $\alpha_i(x, \cdot)$ 를 열린 채로 보면 $V \mapsto \int \alpha_i(x, y)V(y), d\mu(y)$ 는 V 에 대해 선형인 적분연산자다. 그러나 α_i 는 $Q(x)$ 를 통해 입력에 의존하고, 분모의 **softmax 정규화가 비선형(비율 구조)** 이다. 따라서 **query → 출력 전체 사상은 비선형 연산자**다. 비선형의 출처를 한 단어로 답하면 **softmax**. (원본의 "bounded linear operator"는 이 구분 없이는 거짓이다.)

"bounded"는 더 강하게 못 박을 수 있다. $\alpha_i(x, \cdot) \geq 0$ 이고 $\int_{\Omega} \alpha_i(x, y), d\mu(y) = 1$ — 즉 **확률측도(Markov 커널)** 다. 가중치 고정 시 연산자 T 는 단순 유계가 아니라 **averaging / stochastic operator**이며, L^{∞} 에서

$$|TV|_{\infty} \leq \int \alpha_i(x, y), |V(y)|, d\mu(y) \leq |V|_{\infty} \cdot \underbrace{\int \alpha_i(x, y), d\mu(y)}_{=1} = |V|_{\infty}$$

이므로 **operator norm ≤ 1 인 contraction** 이다. 이산 버전에서는 α_i 가 row-stochastic 행렬 A_i ($n \times n$, 행합 = 1)이고 $|A_i|_{\infty} = 1$, 고유값 1을 1에 대해 갖는 stochastic operator다.

L^p 로 가면 깨질 수 있다 (노름 의존성). Jensen ($\phi(t) = |t|^p$ convex, $\alpha_i(x, \cdot)$ 가 확률측도)으로

$$|TV(x)|^p \leq \int \alpha_i(x, y), |V(y)|^p, d\mu(y),$$

x 로 적분하고 Tonelli로 순서를 바꾸면

$$|TV|_{p^p} \leq \int \Omega |V(y)|^p \underbrace{\left(\int_{\Omega} \alpha_i(x, y), d\mu(x) \right)}_{=, c(y)}, d\mu(y).$$

여기서 막힌다. contraction이 되려면 $c(y) \leq 1$ 이어야 하는데, softmax가 보장하는 것은 $\int \alpha_i(x, y), d\mu(y) = 1$ (**key(y) 방향** 정규화)뿐이다. $c(y) = \int \alpha_i(x, y), d\mu(x)$ 는 **query(x) 방향** 합이라 1이라는 보장이 없다. 이산으로 보면 A_i 는 행합 = 1 이지만 열합은 임의이므로 일반적으로 **doubly-stochastic**이 아니다.

공간	contraction 여부
L^{∞}	항상 ($ A_i _{\infty} = 1$, 행합만 필요)
$L^p; (1 \leq p < \infty)$	doubly-stochastic (열합 ≤ 1)이라는 추가 조건이 없으면 깨질 수 있음

같은 연산자가 어느 공간(노름)에서 보느냐에 따라 contraction이 되기도, 안 되기도 한다. Hilbert(L^2 , 내적)를 벗어나 L^p /Banach로 일반화할 때 연산자 성질이 **norm-dependent** 하게 바뀐다는 점이, 어텐션을 L_p 공간(예: Hölder 쌍대성 기반)으로 확장하는 연구의 출발점이다.

정직하게 덧붙일 것 — 연속/르벡 framing은 이상하다. 실제 transformer에서 Ω 는 유한한 토큰 집합, μ 는 계량측도(counting measure), "적분"은 유한합이다. 르벡 적분을 끌어오려면 *continuum limit*(토큰 수 $\rightarrow \infty$, 어텐션을 측도 흐름/interacting particle로 보는 관점)을 명시적으로 채택한다고 선언해야 한다. framing 자체는 유효하지만 "이건 연속 이상하다"라는 한 줄을 반드시 박아둔다.

4. 정리

항목	교정된 설명
W_i^Q, W_i^K, W_i^V	head별 차원축소 선형사상 ($\mathbb{R}^{d_{model} \times d_k}$ 또는 d_v). idempotent "projection"이 아님
W^O	concat된 value 출력을 흡수해 d_{model} 로 복원. $\mathbb{R}^{(h \cdot d_v) \times d_{model}}$
다중 Head	각 head = full 상호작용의 rank-d_k 슬라이스 . h 개의 독립 저랭크 부분공간을 병렬 관찰
연산자 해석	value V 엔 선형, query x 엔 비선형 (softmax). 가중치 고정 시 Markov 평균연산자
노름/공간	L^∞ contraction은 항상, L^p 는 doubly-stochastic 필요
측도 관점	실제로 유한 토큰 = 계량측도, 유한합. 르벡/연속은 <i>continuum limit 이상화</i> 임을 명시

부록: 원본 대비 교정 내역

- W^O 차원. 원본 $W^O \in \mathbb{R}^{d_k \times d_{model}} \rightarrow$ 교정 $\mathbb{R}^{(h \cdot d_v) \times d_{model}}$. (concat이 h 개를 붙여 $h \cdot d_v$ 로 부풀린다는 점 누락. W^O 는 query/key가 아니라 **value 결합** 쪽 행렬.)
- "**low-rank projection**". "projection"은 부정확(idempotent 아님, 공역 다름) $\rightarrow$ **차원 축소 선형사상**. "low-rank"는 맞되 근거는 $\text{rank}(W_i^Q (W_i^K)^\top) \leq d_k$.
- "**bounded linear operator**". value엔 선형이지만 query엔 비선형(softmax) $\rightarrow$ 구분 명시. "bounded"는 **Markov 평균연산자**, $L^\infty \text{ norm} \leq 1$ **contraction**으로 정밀화.

4. **르벡/측도 framing.** 유한 토큰 = 계량측도/유한합임을 인정하고, 연속 적분은 *continuum limit* 이상화로 명시.
5. **(추가)** L^p contraction은 doubly-stochastic 조건이 필요 — 노름 의존성을 별도 진술로 추가.